

陪伴小夜灯：两种模型方案对比

方案 1：分体式语音链路 / 方案 2：MiniCPM-o 端到端链路

用途：产品技术选型参考 日期：2026-08-21

一句话结论：方案 1 更适合当前电脑 Demo 和 RK3576 逐步落地；方案 2 交互更完整，但 9B 规模较重，更适合高性能电脑或云端验证。

1. 两种方案的流程

方案 1 分体式模型链路	方案 2 MiniCPM-o 一体化链路
用户语音 → Whisper Small → Qwen2.5-3B → VoxCPM-0.5B → 回答语音	用户语音 → MiniCPM-o 4.5 → 回答文字 + 回答语音 (模型内部统一处理)

注：当前 Demo 的 TTS 仍是 Windows SAPI；方案 1 中的 VoxCPM-0.5B 属于拟接入升级项。

2. 模型职责区别

环节	方案 1	方案 2
听懂用户	Whisper Small：语音转文字	MiniCPM-o 内部的 Whisper-medium
生成回答	Qwen2.5-3B：理解和生成文字	MiniCPM-o 内部的 Qwen3-8B
生成声音	VoxCPM-0.5B：文字转自然语音	MiniCPM-o 内部的 CosyVoice2
设备控制	外部灯控规则与状态机	仍需保留外部灯控规则与状态机

3. 核心差异

对比项	方案 1：分体式	方案 2：MiniCPM-o
模型结构	三个模型各司其职，可独立替换	一个 9B 端到端多模态模型
语音交互	分阶段处理，链路清晰	可边听边说，支持全双工和打断

对比项	方案 1：分体式	方案 2：MiniCPM-o
声音能力	VoxCPM 支持自然语音和克隆	内置可配置语音、克隆和角色扮演
资源需求	Qwen 约 2GB 显存；加入 VoxCPM 后整机需进一步实测	9B 模型，官方推荐 NVIDIA GPU；资源明显更高
开发维护	模块化，容易定位和替换单个模型	接入较集中，但问题定位和端侧适配更复杂
灯控可靠性	确定性规则直接执行，容易验收	仍应由外部规则执行，不能完全交给模型
RK3576 适配	可以逐个模型量化、转换和降级	完整版不适合直接部署，转换难度较高
适用阶段	当前 Demo、端侧原型、量产迭代	高性能电脑演示或云端语音助手

4. 选择建议

推荐主方案：优先采用方案 1。它与现有 Demo 架构一致，模型可逐步替换，也更方便未来针对 RK3576 分别做 ASR、对话模型和 TTS 的量化优化。

方案 2 的定位：作为高体验对照方案，在高性能电脑或云端验证“边听边说、自然打断、声音克隆”等完整交互，不作为当前 RK3576 首选。

共同原则：无论采用哪种模型，唤醒词、声纹权限、灯控安全确认和设备状态机都应保留在模型外部。

5. 参考资料

VoxCPM 官方仓库：<https://github.com/OpenBMB/VoxCPM>
VoxCPM-0.5B 模型卡：<https://huggingface.co/openbmb/VoxCPM-0.5B>
MiniCPM-o 4.5 模型卡：https://huggingface.co/openbmb/MiniCPM-o-4_5